

Previsão de Demanda Aérea

Região de Los Angeles (EUA)

Marcelo Xavier Guterres

April 6, 2026

Objetivo

Formular um modelo de previsão de demanda para a cidade de Los Angeles usando a série de dados históricos fornecida.

- Estudo de caso aplicado ao tráfego aéreo
- Base histórica como ponto de partida do modelo
- Foco em estrutura explicativa e previsão

Recorte da aula

Este bloco abre a análise do caso de Los Angeles e define o problema de previsão que será desenvolvido nos próximos slides.

Gauss-Markov e BLUE

Sob os pressupostos clássicos da regressão linear, o estimador de MQO é BLUE.

BLUE = *Best Linear Unbiased Estimator*

Melhor Estimador Linear Não Viesado

A ideia de BLUE combina três pontos: o estimador é linear, não viesado e, entre os estimadores lineares não viesados, apresenta a menor variância.

Pressupostos em linguagem

- **Linearity in parameters:** Linearidade nos parâmetros
- **Random sampling:** Amostragem aleatória
- **No perfect multicollinearity:** Ausência de multicolinearidade perfeita
- **Zero conditional mean:** Média condicional nula dos erros
- **Homoskedasticity:** Homocedasticidade

Alerta: se esses pressupostos falham, os coeficientes podem perder interpretação econômetrica e as previsões podem ficar viesadas ou pouco eficientes.

Gauss-Markov em Forma Matemática

Modelo linear

$$y = X\beta + u$$

$$E(u | X) = 0$$

$$\text{Var}(u | X) = \sigma^2$$

Tradução econômetrica

$E(u | X) = 0$: dado o conjunto de regressores, o erro tem média zero. Isso sustenta o não viés dos coeficientes.

$\text{Var}(u | X) = \sigma^2$: a variância dos erros é constante. Em termos práticos, isso significa homocedasticidade.

Leitura para a aula: ao analisar resíduos, estamos justamente verificando se essas hipóteses parecem plausíveis nos dados.

Seção 1

Definição das variáveis

Variável a Ser Explicada e Variáveis Explanatórias

Variável dependente

PAX Passageiros

Relação derivada

$$PPC = \frac{PAX}{POP}$$

Variáveis candidatas a explicativas

PPC Passageiros per capita


RPC Renda per capita

POP População

YDD Yield

Evolução Histórica do PAX

Gráfico de dispersão



Cálculo da Correlação

Forma compacta


$$r_{xy} = \frac{\text{cov}(x, y)}{\sigma_x \sigma_y}$$

Forma expandida

$$r_{xy} = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_{i=1}^n (x_i - \bar{x})^2 \sum_{i=1}^n (y_i - \bar{y})^2}}$$

Mede a intensidade e o sinal da associação linear entre duas variáveis.

Matriz de Correlação



Recorte da aula

Em modelos econométricos, a correlação funciona como uma triagem inicial: mostra quais variáveis têm associação linear mais forte com a demanda e sinaliza relações entre regressores.

Modelo 01 - $PAX = \beta_1 + \beta_2(POP)$

Coeficientes estimados

	Coeficientes	Erro padrão	Stat <i>t</i>	valor- <i>P</i>	95% inferiores	95% superiores
Interseção	-52,3124	3,5523	-14,7264	0,0000	-59,6608	-44,9639
POP (000)	7,8348	0,2847	27,5198	0,0000	7,2459	8,4238

Estatísticas do ajuste

<i>Estatística de regressão</i>	
R múltiplo	0,9852
R-Quadrado	0,9705
R-quadrado ajustado	0,9692
Erro padrão	2,5268
Observações	25


ANOVA da regressão

	gl	SQ	MQ	F	F de significação
Regressão	1,0	4835,2512	4835,2512	757,3400	0,0000
Resíduo	23,0	146,8439	6,3845		
Total	24,0	4982,0951			

Modelo 01 - Gráfico de ajuste

Recorte da aula

O gráfico compara valores observados e ajustados para verificar se a reta acompanha o padrão da demanda ao longo da variação de POP.



Modelo 02 - $PAX = \beta_1 + \beta_2(RPC)$

Coeficientes estimados

	Coeficientes	Erro padrão	Stat <i>t</i>	valor- <i>P</i>	95% inferiores	95% superiores
Interseção	-87,9732	14,2807	-6,1603	0,0000	-117,5152	-58,4313
RPC (000)	8,1464	0,8746	9,3145	0,0000	6,3371	9,9556

Estatísticas do ajuste

<i>Estatística de regressão</i>	
R múltiplo	0,8891
R-Quadrado	0,7905
R-quadrado ajustado	0,7813
Erro padrão	6,7373
Observações	25


ANOVA da regressão

	gl	SQ	MQ	F	F de significação
Regressão	1,0	3938,1094	3938,1094	86,7603	0,0000
Resíduo	23,0	1043,9857	45,3907		
Total	24,0	4982,0951			

Modelo 02 - Gráfico de ajuste

Recorte da aula

O gráfico compara valores observados e ajustados para verificar se a reta acompanha o padrão da demanda ao longo da variação de RPC.



Modelo 03 - $PAX = \beta_1 + \beta_2(YDD)$

Coeficientes estimados

	Coeficientes	Erro padrão	Stat <i>t</i>	valor- <i>P</i>	95% inferiores	95% superiores
Interseção	129,1084	3,8523	33,5148	0,0000	121,1393	137,0774
YDD	-4,9369	0,2217	-22,2658	0,0000	-5,3956	-4,4783

Estatísticas do ajuste

<i>Estatística de regressão</i>	
R múltiplo	0,9776
R-Quadrado	0,9557
R-quadrado ajustado	0,9537
Erro padrão	3,0990
Observações	25

ANOVA da regressão


	gl	SQ	MQ	F	F de significação
Regressão	1,0	4761,2092	4761,2092	495,7664	0,0000
Resíduo	23,0	220,8859	9,6037		
Total	24,0	4982,0951			

Modelo 03 - Gráfico de ajuste

Recorte da aula

O gráfico compara valores observados e ajustados para verificar se a reta acompanha o padrão da demanda ao longo da variação de YDD.

YDD Plotagem de ajuste de linha




Comparação Visual dos Ajustes

Modelo 01: POP

POP (000) Plotagem de ajuste de linha


• PAX (000) • Previsão(a) PAX (000)



Modelo 02: RPC

RPC (000) Plotagem de ajuste de linha


• PAX (000) • Previsão(a) PAX (000)



Modelo 03: YDD

YDD Plotagem de ajuste de linha

• PAX (000) • Previsão(a) PAX (000)



Leitura visual

O ajuste com YDD mostra alinhamento visual forte e padrão mais organizado; POP também ajusta bem, enquanto RPC apresenta maior dispersão ao redor da reta.

Análise de Resíduos

Por que analisar os resíduos?

Em modelos econométricos, os resíduos mostram a parte da demanda que o modelo não conseguiu explicar. Eles ajudam a verificar se a especificação está coerente e se os pressupostos da regressão são plausíveis.

O que pode dar errado?

Se os resíduos não oscilam em torno de zero, isso pode indicar viés sistemático, variável omitida, relação funcional inadequada ou problema de tendência temporal não capturada.

Importância prática

Um modelo com resíduos mal comportados pode produzir previsões enviesadas, intervalos de confiança pouco confiáveis e interpretações equivocadas sobre o efeito das variáveis explicativas.

Regra intuitiva

Espera-se que os resíduos sejam pequenos, sem padrão claro e com média próxima de zero. Quando isso não ocorre, o bom ajuste visual ou um alto R^2 podem ser enganosos.

Teste de Durbin-Watson (DW)

Fórmula

$$DW = \frac{\sum_{t=2}^n (\hat{e}_t - \hat{e}_{t-1})^2}{\sum_{t=1}^n \hat{e}_t^2}$$

Leitura didática

O teste DW verifica se os resíduos apresentam autocorrelação serial. Em séries temporais, isso ajuda a avaliar se o modelo deixou padrões sistemáticos no tempo.

Hipóteses e interpretação

H_0 : ausência de autocorrelação serial nos resíduos

H_1 : presença de autocorrelação serial nos resíduos

- $DW \approx 2$: ausência de autocorrelação
- $DW < 2$: indício de autocorrelação positiva
- $DW > 2$: indício de autocorrelação negativa

Na aula, usamos a leitura do valor calculado em relação ao limite inferior crítico.


Modelo 01 - DW e Resíduos

Cálculo DW (recorte)

Obs.	Previsto(a)	Resíduo	$(\hat{e}_t - \hat{e}_{t-1})^2$	$\hat{e}^2$
1	26,0360	-1,7920	—	3,2112
2	27,2504	-3,2374	2,0892	10,4806
3	27,5324	-1,3794	3,4520	1,9028
...				
23	65,7037	-2,2827	0,1085	5,2109
24	66,8555	-1,7155	0,3218	2,9428
25	67,5763	1,9617	13,5218	3,8484
Total			102,0967	146,8439

Resumo do teste

Indicador	Resultado
DW	0,6953
d_L (referência)	1,288
Decisão	Rejeita H_0
Leitura	Autocorrelação serial positiva



O valor de DW fica abaixo do limite crítico inferior. A leitura é de autocorrelação serial positiva nos resíduos do modelo com POP.

Modelo 02 - DW e Resíduos


Cálculo DW (recorte)

Obs.	Previsto(a)	Resíduo	$(\hat{e}_t - \hat{e}_{t-1})^2$	$\hat{e}^2$
1	22,4101	1,8339	—	3,3631
2	20,6179	3,3951	2,4374	11,5266
3	25,6279	0,5251	8,2370	0,2757
...				
23	53,2034	10,2176	3,6149	104,3991
24	51,5253	13,6147	11,5406	185,3612
25	52,6495	16,8885	10,7178	285,2228
Total			174,0751	1043,9857

Resumo do teste

Indicador	Resultado
DW	0,1667
d_L (referência)	1,288
Decisão	Rejeita H_0
Leitura	Autocorrelação serial positiva

RPC (000) Plotagem de resíduos



Esta é a regressão faltante no bloco de resíduos. O DW do modelo com RPC é ainda menor, reforçando a presença de autocorrelação serial positiva.

Modelo 03 - DW e Resíduos


Cálculo DW (recorte)

Obs.	Previsto(a)	Resíduo	$(\hat{e}_t - \hat{e}_{t-1})^2$	$\hat{e}^2$
1	26,2224	-1,9784	—	3,9142
2	25,6794	-1,6664	0,0974	2,7768
3	26,7161	-0,5631	1,2171	0,3171
...				
23	65,4711	-2,0501	6,9982	4,2031
24	63,4964	1,6436	13,6440	2,7016
25	66,8041	2,7339	1,1886	7,4741
Total			317,8453	220,8859

Resumo do teste

Indicador	Resultado
DW	1,4390
d_L (referência)	1,288
Decisão	Não rejeita H_0
Leitura	Ausência de autocorrelação

YDD Plotagem de res'íduos



O valor de DW é mais próximo da região aceitável. Neste caso, a aula interpreta o modelo com YDD como sem evidência relevante de autocorrelação.

Conclusão dos Testes DW

Síntese dos três modelos

Modelo	DW	Leitura
$PAX = f(\text{POP})$	0,6953	Autocorrelação positiva
$PAX = f(\text{RPC})$	0,1667	Autocorrelação positiva
$PAX = f(\text{YDD})$	1,4390	Sem evidência relevante

Leitura para a aula

Os modelos com POP e RPC ajustam a série, mas deixam dependência temporal nos resíduos. O modelo com YDD tem comportamento residual mais compatível com os pressupostos.

O que muda quando há autocorrelação?

- Os erros deixam de ser independentes no tempo.
- Os testes t e F podem ficar distorcidos.
- A inferência sobre significância perde confiabilidade.
- O modelo pode parecer bom no ajuste, mas ser fraco para interpretação econométrica.

O que muda quando não há autocorrelação?

O padrão dos resíduos fica mais consistente com o uso do modelo.

A leitura dos coeficientes e dos testes estatísticos passa a ser mais defensável.

Seção 2

Regressão linear múltipla

Modelos Múltiplos Testados

Combinações avaliadas

- Modelo 04:
 $PAX = f(POP, YDD, RPC)$
- Modelo 05: $PAX = f(POP, YDD)$
- Modelo 06: $PAX = f(POP, RPC)$
- Modelo 07: $PAX = f(YDD, RPC)$

Leitura da aula

O objetivo não é apenas aumentar o R^2 . A comparação entre combinações serve para avaliar ganho de ajuste e comportamento dos resíduos ao mesmo tempo.

Modelo 04 -

$$PAX = \beta_1 + \beta_2(POP) + \beta_3(YDD) + \beta_4(RPC)$$

Coeficientes estimados

	Coeficientes	Erro padrão	Stat t	valor-P	95% inferiores	95% superiores
Interseção	5,0313	15,5019	0,3246	0,7487	-27,2067	37,2692
POP (000)	4,1580	0,6508	6,3891	0,0000	2,8046	5,5114
YDD	-1,8429	0,4051	-4,5493	0,0002	-2,6853	-1,0004
RPC (000)	1,2099	0,4096	2,9535	0,0076	0,3580	2,0618

Estatísticas do ajuste

<i>Estatística de regressão</i>	
R múltiplo	0,9946
R-Quadrado	0,9892
R-quadrado ajustado	0,9876
Erro padrão	1,6013
Observações	25

ANOVA da regressão

	gl	SQ	MQ	F	F de significação
Regressão	3,0	4928,2510	1642,7503	640,6968	0,0000
Resíduo	21,0	53,8441	2,5640		
Total	24,0	4982,0951			

Modelo 04 - DW e Resíduos


Cálculo DW (recorte)

Obs.	Previsto(a)	Resíduo	$(\hat{e}_t - \hat{e}_{t-1})^2$	$\hat{e}^2$
1	24,6001	-0,3561	—	0,1268
2	24,7757	-0,7627	0,1653	0,5818
3	26,0565	0,0965	0,7383	0,0093
...				
23	64,8763	-1,4553	0,9242	2,1178
24	64,5011	0,6389	4,3855	0,4082
25	66,2853	3,2527	6,8319	10,5799
Total			47,6768	53,8441

Resumo do teste

Indicador	Resultado
DW	0,8855
d_L (referência)	1,288
Decisão	Rejeita H_0
Leitura	Autocorrelação serial positiva

Plotagem de resíduos por observação



Mesmo com o melhor ajuste entre os modelos, o valor de DW permanece abaixo do limite crítico. O ganho de ajuste não elimina a autocorrelação serial.

Modelo 05 - $PAX = \beta_1 + \beta_2(POP) + \beta_3(YDD)$

Coeficientes estimados

	Coeficientes	Erro padrão	Stat <i>t</i>	valor- <i>P</i>	95% inferiores	95% superiores
Interseção	22,1901	16,7054	1,3283	0,1977	-12,4549	56,8351
POP (000)	4,6944	0,7264	6,4625	0,0000	3,1879	6,2009
YDD	-2,0829	0,4613	-4,5155	0,0002	-3,0395	-1,1263

Estatísticas do ajuste

<i>Estatística de regressão</i>	
R múltiplo	0,9923
R-Quadrado	0,9847
R-quadrado ajustado	0,9833
Erro padrão	1,8612
Observações	25

ANOVA da regressão

	gl	SQ	MQ	F	F de significação
Regressão	2,0	4905,8842	2452,9421	708,0970	0,0000
Resíduo	22,0	76,2109	3,4641		
Total	24,0	4982,0951			

Modelo 05 - DW e Resíduos


Cálculo DW (recorte)

Obs.	Previsto(a)	Resíduo	$(\hat{e}_t - \hat{e}_{t-1})^2$	$\hat{e}^2$
1	25,7266	-1,4826	—	2,1982
2	26,2252	-2,2122	0,5322	4,8937
3	26,8316	-0,6786	2,3519	0,4605
...				
23	66,0534	-2,6324	1,8120	6,9293
24	65,9103	-0,7703	3,4673	0,5933
25	67,7377	1,8003	6,6079	3,2411
Total			70,2973	76,2109

Resumo do teste

Indicador	Resultado
DW	0,9224
d_L (referência)	1,288
Decisão	Rejeita H_0
Leitura	Autocorrelação serial positiva

Plotagem de resíduos por observação



O modelo com POP e YDD melhora muito o ajuste, mas ainda apresenta autocorrelação serial positiva. A especificação melhora, mas o problema residual não desaparece.

Modelo 06 - $PAX = \beta_1 + \beta_2(POP) + \beta_3(RPC)$

Coeficientes estimados

	Coeficientes	Erro padrão	Stat t	valor-P	95% inferiores	95% superiores
Interseção	-63,5349	4,9931	-12,7245	0,0000	-73,8900	-53,1798
POP (000)	6,6590	0,4795	13,8864	0,0000	5,6645	7,6535
RPC (000)	1,5838	0,5525	2,8666	0,0090	0,4380	2,7295

Estatísticas do ajuste

<i>Estatística de regressão</i>	
R múltiplo	0,9892
R-Quadrado	0,9785
R-quadrado ajustado	0,9766
Erro padrão	2,2044
Observações	25

ANOVA da regressão

	gl	SQ	MQ	F	F de significação
Regressão	2,0	4875,1848	2437,5924	501,6079	0,0000
Resíduo	22,0	106,9103	4,8596		
Total	24,0	4982,0951			

Modelo 06 - DW e Resíduos


Cálculo DW (recorte)

Obs.	Previsto(a)	Resíduo	$(\hat{e}_t - \hat{e}_{t-1})^2$	$\hat{e}^2$
1	24,5147	-0,2707	—	0,0733
2	25,1984	-1,1854	0,8367	1,4052
3	26,4121	-0,2591	0,8580	0,0672
...				
23	64,2156	-0,7946	0,0004	0,6315
24	64,8683	0,2717	1,1372	0,0738
25	65,6994	3,8386	12,7222	14,7345
Total			81,0155	106,9103

Resumo do teste

Indicador	Resultado
DW	0,7578
d_L (referência)	1,288
Decisão	Rejeita H_0
Leitura	Autocorrelação serial positiva

Plotagem de resíduos por observação



A combinação entre POP e RPC melhora o ajuste em relação ao modelo simples com RPC, mas os resíduos continuam com autocorrelação positiva relevante.

Modelo 07 - $PAX = \beta_1 + \beta_2(YDD) + \beta_3(RPC)$

Coeficientes estimados

	Coeficientes	Erro padrão	Stat <i>t</i>	valor- <i>P</i>	95% inferiores	95% superiores
Interseção	82,0009	16,3540	5,0141	0,0001	48,0848	115,9170
YDD	-4,0291	0,3634	-11,0860	0,0000	-4,7828	-3,2753
RPC (000)	1,9402	0,6594	2,9424	0,0075	0,5727	3,3077

Estatísticas do ajuste

<i>Estatística de regressão</i>	
R múltiplo	0,9840
R-Quadrado	0,9682
R-quadrado ajustado	0,9653
Erro padrão	2,6842
Observações	25

ANOVA da regressão

	gl	SQ	MQ	F	F de significação
Regressão	2,0	4823,5866	2411,7933	334,7420	0,0000
Resíduo	22,0	158,5085	7,2049		
Total	24,0	4982,0951			


Modelo 07 - DW e Resíduos

Cálculo DW (recorte)

Obs.	Previsto(a)	Resíduo	$(\hat{e}_t - \hat{e}_{t-1})^2$	$\hat{e}^2$
1	24,3251	-0,0811	—	0,0066
2	23,4550	0,5580	0,4084	0,3113
3	25,4944	0,6586	0,0101	0,4338
...				
23	63,6902	-0,2692	3,2051	0,0725
24	61,6789	3,4611	13,9152	11,9795
25	64,6461	4,8919	2,0471	23,9308
Total			180,6276	158,5085

Resumo do teste

Indicador	Resultado
DW	1,1395
d_L (referência)	1,288
Decisão	Rejeita H_0
Leitura	Autocorrelação serial positiva



Este é o melhor caso entre os modelos múltiplos em termos de DW, mas ainda abaixo do limite crítico usado na aula. Portanto, também não elimina a autocorrelação.

Comparação dos Modelos

Coefficientes estimados

Modelo	Interseção	POP	YDD	RPC	$R^2_{aj.}$	DW
PAX = f(POP)	-52,3124	7,8348	–	–	0,9692	0,6953
PAX = f(RPC)	-87,9732	–	–	8,1464	0,7813	0,1667
PAX = f(YDD)	129,1084	–	-4,9369	–	0,9537	1,4390
PAX = f(POP,YDD,RPC)	5,0313	4,1580	-1,8429	1,2099	0,9876	0,8855
PAX = f(POP,YDD)	22,1901	4,6944	-2,0829	–	0,9833	0,9224
PAX = f(POP,RPC)	-63,5349	6,6590	–	1,5838	0,9766	0,7578
PAX = f(YDD,RPC)	82,0009	–	-4,0291	1,9402	0,9653	1,1395

Leitura do exercício

A tabela resume todas as combinações testadas na aula. Ela mostra como os coeficientes mudam quando a especificação passa de simples para múltipla.

Escolha do Modelo

Ajuste, resíduos e decisão

Modelo	R^2	$R^2_{aj.}$	Erro padrão	DW	Leitura
PAX = f(POP)	0,9705	0,9692	2,5268	0,6953	Autocorrelação positiva
PAX = f(RPC)	0,7905	0,7813	6,7373	0,1667	Autocorrelação positiva
PAX = f(YDD)	0,9557	0,9537	3,0990	1,4390	Sem evidência relevante
PAX = f(POP,YDD,RPC)	0,9892	0,9876	1,6013	0,8855	Autocorrelação positiva
PAX = f(POP,YDD)	0,9847	0,9833	1,8612	0,9224	Autocorrelação positiva
PAX = f(POP,RPC)	0,9785	0,9766	2,2044	0,7578	Autocorrelação positiva
PAX = f(YDD,RPC)	0,9682	0,9653	2,6842	1,1395	Autocorrelação positiva

Conclusão econométrica

Os modelos múltiplos aumentam o poder de ajuste, mas continuam com evidência de autocorrelação serial positiva. Na lógica da aula, isso enfraquece a inferência.

Modelo escolhido

O modelo simples com YDD não tem o maior R^2 , mas é o mais consistente com o teste DW. Por isso, ele aparece como a escolha mais defensável ao final do exercício.

Interpretação dos Coeficientes

Modelo escolhido: $PAX = f(YDD)$

Equação estimada

$$\widehat{PAX} = 129,11 - 4,94 \times YDD$$

Ambos os coeficientes são significativos ao nível de 1% ($p < 0,0001$).

O modelo explica **95,6%** da variação histórica da demanda ($R^2 = 0,9557$).

Leitura dos parâmetros

Intercepto ($\hat{\beta}_1 = 129,11$): valor teórico da demanda quando $YDD = 0$. Não tem interpretação prática direta, mas âncora a reta no espaço.

Inclinação ($\hat{\beta}_2 = -4,94$): para cada aumento de 1 unidade no yield, a demanda cai em média **4,94 milhões de passageiros**. O sinal negativo é coerente com a lógica econômica: tarifa mais alta reduz demanda.

Previsão com o Modelo Escolhido

Aplicação prática

Passo a passo da previsão

1. **Projetar o regressor:** definir o valor futuro de YDD com base em cenário econômico.

2. **Aplicar a equação:**

$$\widehat{PAX} = 129,11 - 4,94 \times YDD_{prev}$$

Exemplo: se $YDD = 11,5$

$$\widehat{PAX} = 129,11 - 4,94 \times 11,5 \approx 72,3$$

3. **Construir intervalo de predição:** a previsão pontual vem acompanhada de incerteza. O intervalo de predição (95%) é mais largo que o intervalo de confiança da média.

Intervalo de confiança vs. de predição

IC da média: estima onde está a *média* de PAX para um dado YDD. Mais estreito.

IP individual: estima onde cairá *uma observação futura* específica. Mais largo, pois inclui a variabilidade individual dos erros.

Regra prática: para decisão de capacidade aeroportuária, usa-se o

IP — o planejador precisa cobrir a variação individual, não apenas a média.

Atenção: a previsão só é válida dentro da faixa histórica de YDD observada. Extrapolar muito além dos dados é arriscado.

Autocorrelação – O Que Fazer a Seguir

Três caminhos possíveis

1. **Incluir tendência temporal:** adicionar $T = 1, 2, \dots, n$ como regressor captura parte do padrão serial não explicado pelo modelo atual. É o caminho mais direto.
2. **Trabalhar com primeiras diferenças:** modelar $\Delta PAX = f(\Delta YDD)$ elimina tendências comuns e pode resolver a autocorrelação estrutural.
3. **Estimação por GLS / Cochrane-Orcutt:** corrige diretamente a estrutura de covariância dos erros. Mais sofisticado, mas preserva os níveis das variáveis.

Por que isso importa?

Com autocorrelação, os erros padrão dos coeficientes ficam subestimados. Isso faz os testes t e F rejeitarem H_0 com mais frequência do que deveriam.

O modelo pode *parecer* significativo estatisticamente, mas a inferência está comprometida.

Recorte da aula: o teste DW não encerra a análise – ele abre a próxima etapa. Detectar o problema é o primeiro passo; corrigi-lo é o exercício seguinte.

Atividade Prática

Mobilidade Aérea Urbana

Atividade Prática

Mobilidade Aérea Urbana em Brasília

Proposta

Usando a mesma metodologia da aula, construa um modelo de regressão para explicar o **movimento de helicópteros no Distrito Federal** e avalie se ele pode ser usado para projetar a demanda por **eVTOLs** na região.

Variável dependente sugerida:

HEL = número de operações de helicópteros no DF (série histórica ANAC)

Variáveis candidatas

RPCDF	Renda per capita do DF
POPDF	População do DF
FROTA	Frota de helicópteros registrados
HELIPT	Número de helipontos ativos
COMB	Preço do combustível de aviação

Questão central

Um modelo calibrado com dados históricos de helicópteros pode ser usado diretamente para prever a demanda por eVTOLs?

Pontos para discussão em grupo:

- O que muda na estrutura de custos entre helicóptero e eVTOL?
- Há substituição ou expansão de demanda?
- Quais pressupostos do modelo precisam ser revistos para uma nova tecnologia?
- O DW seria relevante nessa série? Por quê?

Entrega esperada: equação estimada, interpretação dos coeficientes, teste

DW e uma discussão qualitativa sobre a transferência do modelo para eVTOLs.

Obrigado.

m.guterres@gmail.com